

Two Moods, One UNet

Trasferimento di stile con adapter LoRA su Stable Diffusion 1.5

Giacomo Antonelli

8 settembre 2026

Abstract

Si addestrano due adapter LoRA sull'UNet congelato di Stable Diffusion 1.5 per fargli apprendere un *mood* visivo astratto da 30 e 35 fotografie personali, e si misura quanto quello stile generalizzi su prompt mai visti in training. Vengono aggiornati 1.594.368 parametri su 861M (lo 0,185%): ogni adapter pesa 6,1 MB contro i ~3,4 GB del modello completo. Entrambi i mood si trasferiscono in modo netto su soggetti estranei ai rispettivi dataset, con delta CLIP positivi ma piccoli (+0,0380 e +0,0195), coerenti con il fatto che la similarità CLIP immagine-immagine è dominata dal contenuto e non dallo stile.

1 Obiettivo

La domanda è se un LoRA di rango 8, applicato alle sole proiezioni di attenzione di un UNet congelato, possa assorbire qualcosa di poco definibile come un *mood* a partire da qualche decina di fotografie, e poi applicarlo a prompt che con quelle fotografie non condividono nulla.

Tutto resta congelato tranne l'adapter: VAE, text encoder e gli 861M parametri dell'UNet. Le matrici LoRA vengono iniettate nelle proiezioni `to_q`, `to_k`, `to_v` e `to_out.0`, cioè dove entra il condizionamento testuale. Lo stile viene agganciato a una frase trigger con cui terminano tutte le caption di training, e la stessa frase lo riattiva in inferenza.

2 Metodo

2.1 Dati

Un mood per sottocartella. Le immagini vengono portate a 512×512 con resize sul lato corto e center crop, e a ciascuna viene associata una caption che termina con il trigger del proprio mood. Il trigger viene registrato in `dataset.json` e propagato fino al checkpoint, così in inferenza non va riscritto a mano: un suffisso diverso da quello di training lascia l'adapter silenziosamente inattivo, ed è stato l'errore più frequente nelle prime prove.

run	trigger	immagini	carattere del dataset
bright	<cjh-bright>	30	saturo, luminoso, illustrativo
scary	<cjh-scary>	35	desaturato, freddo, nebbioso

Table 1: I due dataset di stile. Il trigger è la sola parte comune a tutte le caption del mood.

2.2 Training

Entrambi i run condividono gli stessi iperparametri, quindi i due adapter differiscono solo per ciò che hanno visto: rango 8, $\alpha = 16$, learning rate 10^{-4} , 1200 step, batch 1 con gradient accumulation 2, risoluzione 512×512 , seed 42.



Figure 1: Tre immagini di training per mood: **bright** in alto, **scary** in basso.

Ogni step campiona un timestep casuale, aggiunge il rumore corrispondente al latente prodotto dal VAE e chiede all'UNet di predirlo; la loss è l'MSE fra rumore predetto e rumore vero, e i gradienti raggiungono le sole matrici LoRA. Il gradient checkpointing e l'fp16 sono ciò che fa stare il training nei 6 GB della GPU usata: su architettura Pascal l'fp16 serve a risparmiare memoria più che ad accelerare.

parametri addestrabili	1.594.368
parametri totali dell'UNet	861.115.332
frazione addestrata	0,185 %
dimensione dell'adapter	6,1 MB
dimensione del modello completo	~3,4 GB
GPU	GTX 1060 6 GB
durata di un run	1h 27m

Table 2: Costo del fine-tuning. Il rapporto fra le ultime due voci è il punto del PEFT.

2.3 Valutazione

Gli 11 prompt di valutazione descrivono soggetti mai visti in training: quattro neutri rispetto a entrambi i mood, tre ambigui, e due per mood scelti per tirare il risultato da una parte. Il seed dipende solo dall'indice del prompt e non dalla variante, quindi base e adapter partono dallo stesso rumore e le differenze sono attribuibili al solo adapter.

La metrica è la similarità CLIP media (`clip-vit-base-patch32`) fra immagini generate e dataset di riferimento del mood. Il valore assoluto non è interpretabile da solo, quindi si riporta il delta rispetto alle stesse immagini generate dal modello base.

3 Risultati

run	base	lora	delta	std	prompt migliorati
bright	0,5877	0,6257	+0,0380	0,0673	7 / 11
scary	0,5571	0,5766	+0,0195	0,0643	8 / 11

Table 3: Similarità CLIP media contro il dataset di riferimento di ciascun mood.

Entrambi i delta sono positivi ed entrambi sono piccoli, il che è l’esito atteso e non un risultato deludente: la similarità CLIP immagine-immagine è dominata dal soggetto, e il soggetto è tenuto fisso fra le colonne per costruzione. La metrica va letta come indizio debole; la griglia di confronto resta la valutazione primaria.

All’ispezione visiva il trasferimento è netto già a scala 1.0, quindi non è stato necessario alcuno sweep sull’intensità dell’adapter. **bright** converte le fotografie in illustrazione: il faro acquista roccia dipinta e cielo da manifesto, il pescatore diventa un ritratto pittorico, la cascata vira su turchese e viola. **scary** lavora invece per sottrazione: toglie saturazione, raffredda la palette e riempie di foschia il piano intermedio, tanto che il bosco diventa giallo-grigio e il lupo nella neve perde quasi tutto il colore. Vale la pena notare che il risultato legge come *inquietudine* e non come horror: non viene aggiunto nulla di trucculento, viene solo rimosso il calore.

Le righe più indicative sono quelle dei soggetti neutri. Una ciotola di frutta e uno skyline non hanno nulla a che vedere con nessuno dei due dataset, eppure entrambi gli adapter li ristilizzano in modo coerente: è esattamente la generalizzazione che l’esperimento voleva verificare.

4 Limiti

- Il trigger porta con sé del significato.** Il tokenizer di CLIP spezza il trigger in pezzi ordinari — ['in', '<', 'cj', 'h', '-', 'scary', '>', 'style'] — e *scary* e *bright* sono parole inglesi che il modello base già comprende. Poiché la colonna BASE non riceve alcun suffisso, una parte dello scarto visibile potrebbe appartenere alla parola e non all’adapter. Una colonna di controllo (modello base *con* il suffisso, senza adapter) separerebbe i due contributi; un trigger privo di senso li separerebbe alla radice, al costo di riaddestrare entrambi i run.
- Le caption non contengono contenuto.** Tutte le caption di un mood sono identiche e si riducono al trigger, quindi l’adapter non ha modo di distinguere stile e soggetto: impara “quando compare questa frase, assomiglia a queste fotografie”. Il captioning automatico (`-caption-mode blip`) descriverebbe separatamente il contenuto di ogni immagine, lasciando al trigger il solo stile.
- Il warmup dura il doppio di quanto configurato.** Allo scheduler viene passato `lr_warmup_steps` moltiplicato per la gradient accumulation, ma `accelerate` lo avanza solo quando l’optimizer compie davvero uno step, cioè una volta per global step. Il warmup è quindi durato 200 step su 1200 invece di 100. Entrambi i run condividono lo stesso percorso di codice e restano confrontabili fra loro; la correzione è di una riga ed è da fare prima del prossimo sweep.
- La dimensione del campione è piccola.** Undici prompt, una immagine per prompt. I delta CLIP hanno deviazione standard superiore alla loro stessa media, quindi non se ne può ricavare una graduatoria fra i due mood.

5 Riproducibilità

1. `python scripts/prepare_dataset.py -mood scary`
2. `python scripts/train_lora.py -mood scary`
3. `python scripts/generate_comparison.py`
4. `python scripts/evaluate_clip.py`

Il flag `-mood` lega in un colpo solo le tre convenzioni del repo:

dataset	data/processed/<mood>
run	outputs/checkpoints/<mood>
trigger	<cjh-<mood>

Senza argomenti, `generate_comparison.py` confronta il modello base con tutti gli adapter addestrati e produce un'unica griglia; il suffisso di attivazione di ciascun adapter viene letto dal suo `run.json`, non passato a mano.

A Griglie di confronto

Ogni riga usa lo stesso seed nelle tre colonne: le differenze sono attribuibili al solo adapter. Gli adapter sono applicati a scala 1.0.



Figure 2: Soggetti neutri rispetto a entrambi i dataset: misurano quanto lo stile si applichi fuori dal proprio dominio.




Figure 3: Soggetti ambigui: è il mood dell'adapter a decidere da che parte farli pendere.



Figure 4: Soggetti che spingono verso l'uno o l'altro mood: il primo verso **scary**, gli altri due verso **bright**.